Proyecto Final: Dashboard de Análisis Estadístico del Dataset Titan

Estudiante: Cristian Steven Rueda Dueñas

Asignatura: Programación para Ciencia de Datos II

Docente: Jeysson Alexander Riaño Pascagaza

Fundación Universitaria Compensar

Programa Ciencia de Datos

Facultad de Ingeniería

Fundación Universitaria Compensar

2026

Contenido

1. Introducción 3
2. Planteamiento del Problema 5
3. Pregunta de Investigación 6
4. Metodología 7
5. Contraste de Hipótesis 8
6. Modelos de Regresión 9
7. Desarrollo del Dashboard 10
7.1. Explicación de las Gráficas del Dashboard 11
7.1.1. Cantidad de sobrevivientes 11
7.1.2. Distribución de edad según supervivencia 12
7.1.3. Tarifa pagada según supervivencia 14
7.1.4. Relación entre edad y tarifa pagada 15
7.1.5. Números de familia a bordo 16
7.1.6. Interpretación General de Dashboard 17
8. Discusión de Resultados 18
9. Conclusiones 19
10. Referencias Bibliográficas 20

1. Introducción

El análisis estadístico y el uso de modelos computacionales constituyen herramientas fundamentales dentro del campo de la ciencia de datos. A través de estos métodos es posible identificar patrones en los datos, evaluar hipótesis, construir modelos predictivos y generar conocimiento que permita comprender fenómenos complejos presentes en diferentes contextos.

Uno de los conjuntos de datos más utilizados en el aprendizaje de técnicas de análisis de datos es el dataset del Titanic. Este conjunto de datos contiene información sobre los pasajeros que viajaban en el famoso transatlántico RMS Titanic, el cual se hundió en 1912 tras colisionar con un iceberg. El análisis de este dataset ha sido ampliamente utilizado para estudiar problemas de clasificación, probabilidad y modelado estadístico.

En actividades anteriores del curso se aplicaron diferentes técnicas estadísticas sobre este conjunto de datos, incluyendo contraste de hipótesis, regresión lineal y regresión logística. Estas técnicas permitieron evaluar relaciones entre variables como la edad de los pasajeros, el número de familiares a bordo, la tarifa pagada y la probabilidad de supervivencia.

En la presente actividad, correspondiente a la etapa de transferencia del curso, se busca integrar los conocimientos adquiridos mediante la construcción de un dashboard interactivo que permita visualizar los resultados del análisis realizado. Para ello se emplean herramientas de programación en Python junto con las bibliotecas Pandas, Plotly y Dash.

El objetivo principal del proyecto es transformar los resultados del análisis estadístico en una herramienta visual e interactiva que facilite la interpretación de los datos y permita explorar diferentes relaciones entre las variables del dataset.

2. Planteamiento del Problema

El hundimiento del Titanic es uno de los eventos históricos más conocidos en la historia de la navegación. Sin embargo, más allá del contexto histórico, el conjunto de datos generado a partir de este evento permite analizar múltiples factores que influyeron en la supervivencia de los pasajeros.

El dataset del Titanic contiene información demográfica y socioeconómica de los pasajeros, incluyendo edad, clase del pasaje, número de familiares a bordo y tarifa pagada. A partir de estos datos es posible estudiar qué variables pudieron haber influido en la probabilidad de supervivencia.

Comprender estas relaciones es importante desde una perspectiva estadística y de análisis de datos, ya que permite aplicar métodos de inferencia estadística, modelos de regresión y técnicas de visualización para identificar patrones relevantes dentro de la información disponible.

3. Pregunta de Investigación

Pregunta de investigación:

¿Existe una relación estadísticamente significativa entre características de los pasajeros, como la edad, el número de familiares a bordo y la tarifa pagada, con la probabilidad de supervivencia en el desastre del Titanic?

4. Metodología

Para el desarrollo del proyecto se siguió una metodología basada en el proceso típico de análisis de datos utilizado en ciencia de datos. Este proceso incluye varias etapas que permiten transformar datos crudos en información útil.

En primer lugar, se realizó la carga y exploración del conjunto de datos utilizando la biblioteca Pandas de Python. Esta etapa permitió identificar la estructura de los datos, los tipos de variables y la presencia de valores faltantes.

Posteriormente se llevó a cabo un proceso de limpieza de datos, eliminando o tratando valores nulos en variables relevantes como la edad de los pasajeros.

Una vez preparados los datos, se aplicaron técnicas de inferencia estadística, específicamente el contraste de hipótesis mediante la prueba t de Student, con el fin de evaluar si existían diferencias significativas entre las edades de los pasajeros que sobrevivieron y aquellos que no sobrevivieron.

Posteriormente se construyeron modelos estadísticos utilizando regresión lineal y regresión logística. La regresión lineal permitió analizar relaciones entre variables continuas, mientras que la regresión logística permitió abordar el problema desde una perspectiva de clasificación.

Finalmente, los resultados obtenidos fueron integrados en un dashboard interactivo desarrollado con Dash y Plotly, el cual permite visualizar los datos mediante gráficos dinámicos.

5. Contraste de Hipótesis

El contraste de hipótesis es una técnica fundamental dentro de la estadística inferencial. Su objetivo es evaluar afirmaciones acerca de parámetros poblacionales utilizando información obtenida a partir de una muestra.

En este proyecto se plantearon dos hipótesis principales:

Hipótesis nula (H0): No existe una diferencia significativa entre la edad promedio de los pasajeros que sobrevivieron y la edad promedio de los pasajeros que no sobrevivieron.

Hipótesis alternativa (H1): Existe una diferencia significativa entre la edad promedio de los pasajeros que sobrevivieron y la edad promedio de los pasajeros que no sobrevivieron.

Para evaluar estas hipótesis se utilizó la prueba t de Student para muestras independientes, la cual es apropiada cuando se comparan las medias de dos grupos diferentes.

El análisis se realizó separando las edades de los pasajeros en dos grupos: aquellos que sobrevivieron y aquellos que no sobrevivieron. Posteriormente se aplicó la prueba estadística para determinar si la diferencia entre las medias era estadísticamente significativa.

6. Modelos de Regresión

La regresión es una técnica estadística ampliamente utilizada para modelar relaciones entre variables.

En este proyecto se implementaron dos tipos de regresión: regresión lineal y regresión logística.

La regresión lineal se utilizó para analizar la relación entre la tarifa pagada por los pasajeros y variables como la edad, el número de hermanos o cónyuges a bordo y el número de padres o hijos que viajaban con el pasajero.

Este modelo permitió evaluar cómo influyen estas variables en el valor de la tarifa pagada.

Por otro lado, la regresión logística se utilizó para modelar la probabilidad de supervivencia. A diferencia de la regresión lineal, este modelo es adecuado cuando la variable dependiente es binaria, es decir, cuando solo puede tomar dos valores posibles.

El modelo de regresión logística permitió estimar probabilidades de supervivencia a partir de variables predictoras como la edad y otras características del pasajero.

7. Desarrollo del Dashboard

Con el objetivo de facilitar la interpretación de los resultados obtenidos durante el análisis estadístico, se desarrolló un dashboard interactivo utilizando el lenguaje de programación R junto con las librerías **Shiny, Plotly y Tidyverse**.

Un dashboard es una herramienta visual que permite presentar información de manera clara, dinámica e interactiva. En el contexto de la ciencia de datos, los dashboards facilitan la exploración de los datos y permiten identificar patrones, tendencias y relaciones entre variables de forma intuitiva.

El dashboard desarrollado permite analizar diferentes características de los pasajeros del Titanic y su relación con la probabilidad de supervivencia. Además, incorpora elementos interactivos como filtros de edad y selección de clase del pasajero, lo cual permite al usuario explorar los datos desde diferentes perspectivas.

La interfaz del dashboard está compuesta por dos secciones principales:

Panel de control (sidebar)

En esta sección se incluyen herramientas interactivas que permiten filtrar los datos, tales como:

- Selección de rango de edad de los pasajeros.
- Selección de la clase del pasajero.

Estos filtros permiten observar cómo cambian las visualizaciones dependiendo de los criterios seleccionados.

Panel principal (main panel)

En esta sección se presentan las visualizaciones generadas a partir de los datos del Titanic. Estas gráficas permiten analizar diferentes relaciones entre variables y comprender mejor los factores asociados con la supervivencia de los pasajeros

7.1. Explicación de las Gráficas del Dashboard

7.1.1. Cantidad de sobrevivientes

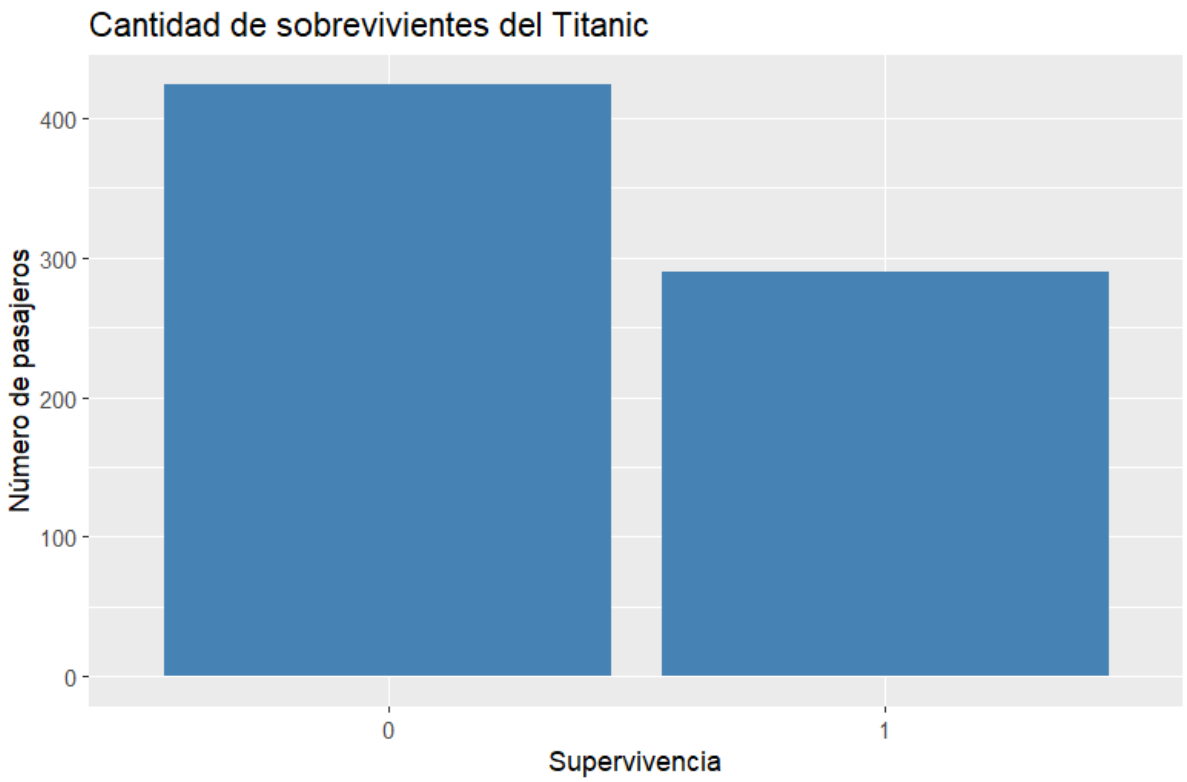

Gráfica 1 cantidad de sobrevivientes

La primera visualización corresponde a un **gráfico de barras** que muestra la cantidad total de pasajeros que sobrevivieron y aquellos que no sobrevivieron al accidente del Titanic.

Esta gráfica permite observar de forma general la distribución de la variable de supervivencia dentro del conjunto de datos. A partir de esta visualización se puede identificar que una proporción considerable de pasajeros no logró sobrevivir al desastre.

Este tipo de gráfico es útil para analizar variables categóricas y permite comprender rápidamente la proporción de cada grupo dentro de la población estudiada.

7.1.2. Distribución de edad según supervivencia

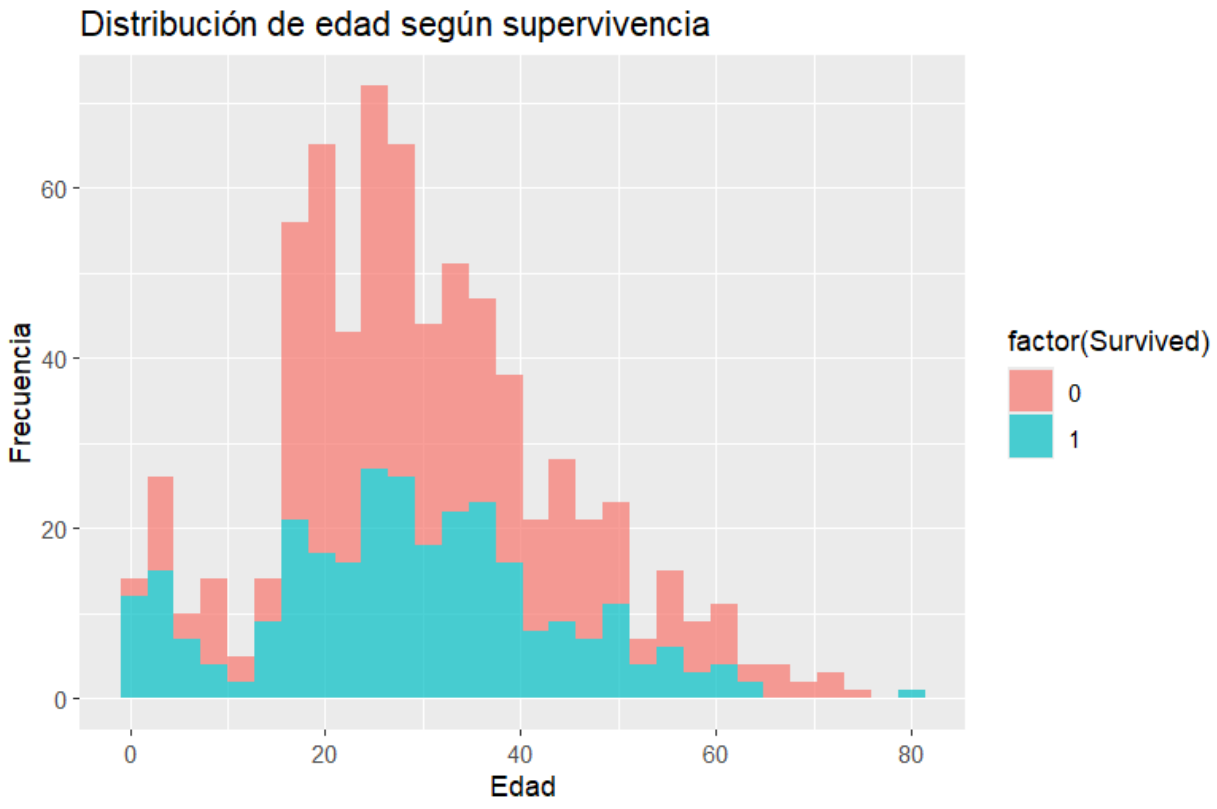

Gráfica 2 Distribución de edad según supervivencia

La segunda visualización corresponde a un histograma que muestra la distribución de edades de los pasajeros, diferenciando entre quienes sobrevivieron y quienes no sobrevivieron.

El objetivo de esta gráfica es analizar si existe alguna relación entre la edad de los pasajeros y la probabilidad de supervivencia.

A partir de esta visualización es posible observar que ciertos rangos de edad presentan diferentes niveles de supervivencia, lo cual sugiere que la edad pudo haber sido un factor relevante durante el proceso de evacuación del barco.

Este tipo de análisis permite complementar los resultados obtenidos en el contraste de hipótesis realizado previamente.

7.1.3. Tarifa pagada según supervivencia

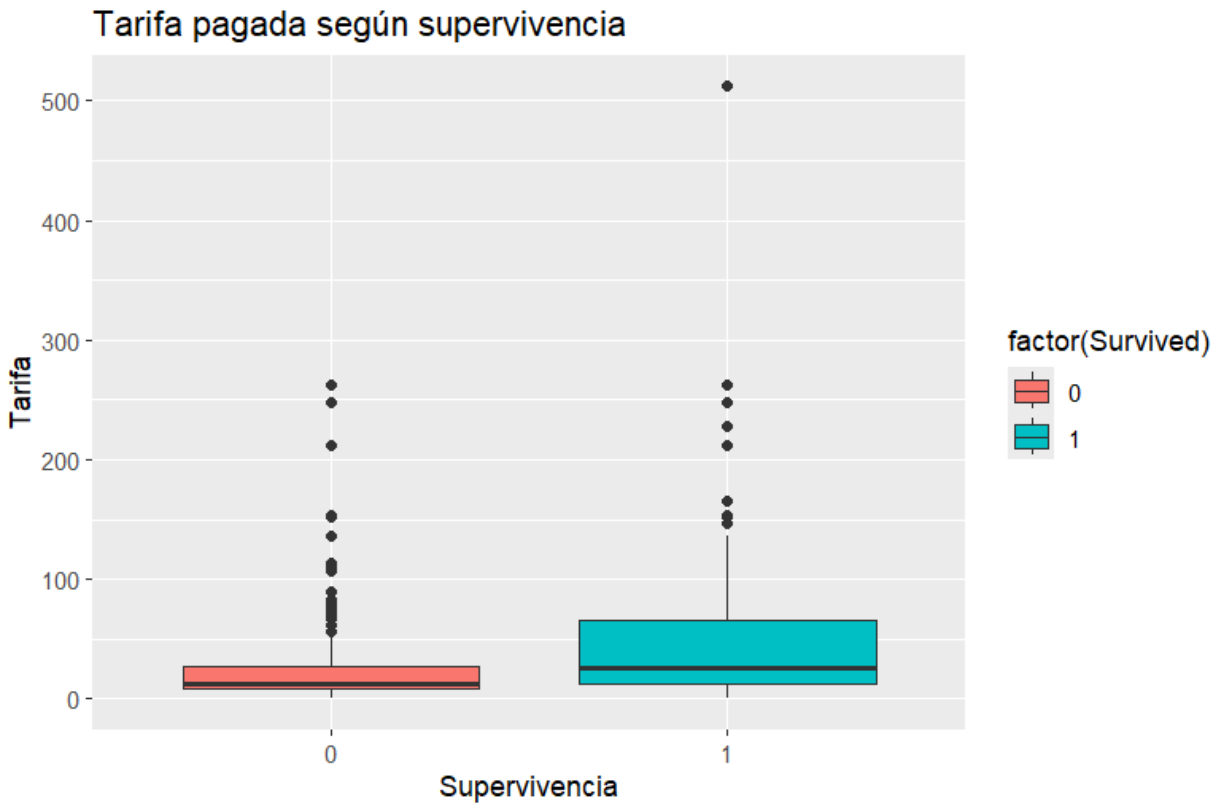

Gráfica 3 Tarifa pagada según supervivencia

La tercera visualización corresponde a un **diagrama de caja (boxplot)** que compara la tarifa pagada por los pasajeros en función de su estado de supervivencia.

Este gráfico permite analizar la distribución de los valores de la variable **Fare**, mostrando la mediana, los cuartiles y posibles valores atípicos.

A partir de esta visualización se puede observar que los pasajeros que sobrevivieron tienden a presentar tarifas promedio más altas en comparación con aquellos que no

sobrevivieron. Esto podría estar relacionado con la clase del pasaje, ya que los pasajeros de clases superiores tenían mayor acceso a recursos durante la evacuación.

7.1.4. Relación entre edad y tarifa pagada

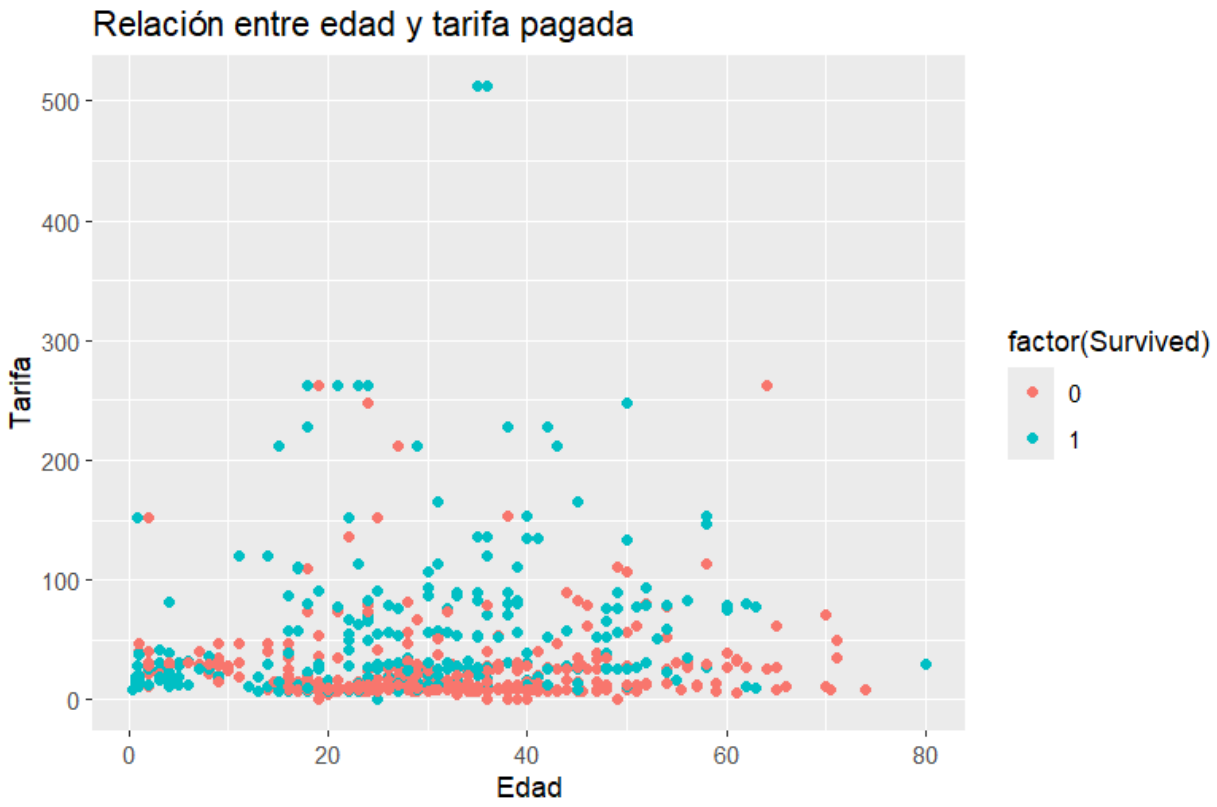

Gráfica 4 Relación entre edad y tarifa pagada

La cuarta visualización corresponde a un **gráfico de dispersión (scatter plot)** que muestra la relación entre la edad de los pasajeros y la tarifa pagada.

Cada punto representa un pasajero dentro del conjunto de datos, y los colores indican si el pasajero sobrevivió o no.

Este tipo de gráfico permite identificar posibles patrones o correlaciones entre variables continuas. Aunque no se observa una relación lineal fuerte entre edad y tarifa, sí permite identificar agrupaciones de pasajeros con características similares.

Este análisis complementa el modelo de regresión lineal desarrollado previamente en el proyecto.

7.1.5. Números de familia a bordo

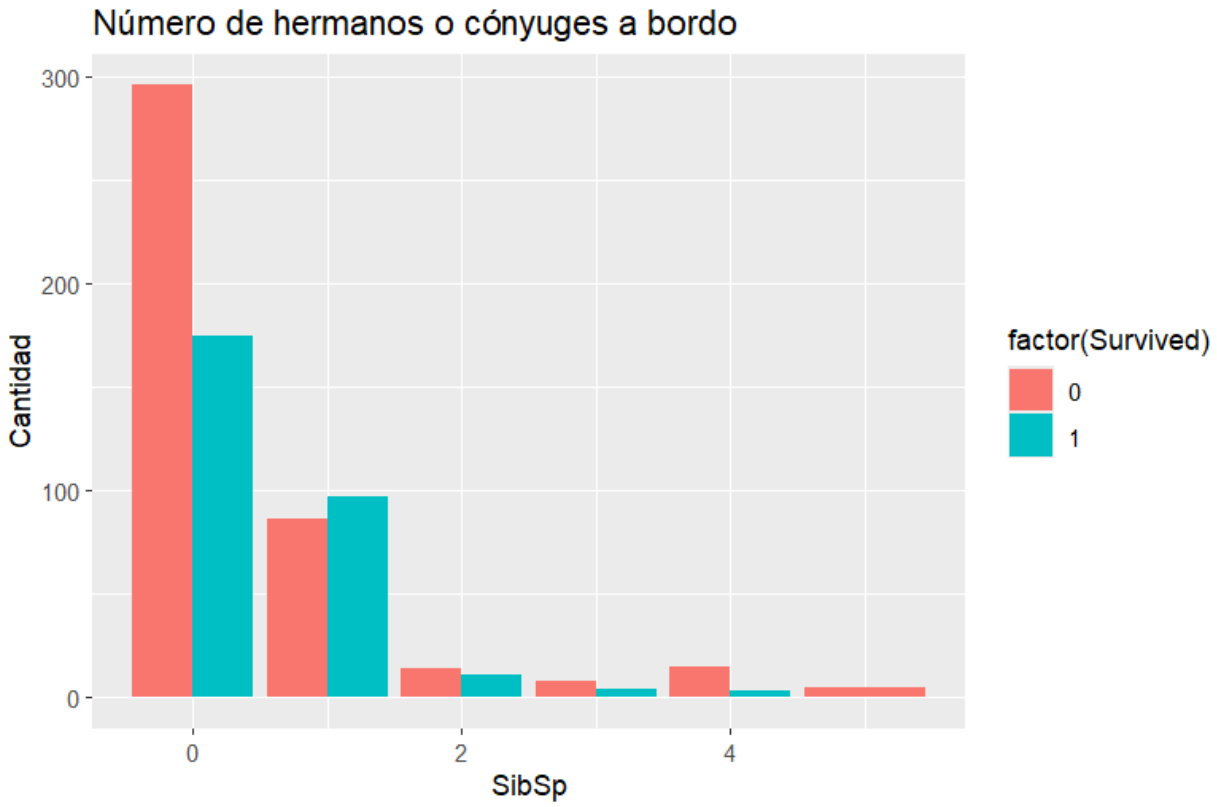

Gráfica 5 Número de hermanos y cónyuges a bordo.

La quinta visualización corresponde a un **gráfico de barras que muestra el número de hermanos o cónyuges a bordo del Titanic (variable SibSp)**.

El objetivo de esta gráfica es analizar si viajar acompañado o solo pudo haber influido en la probabilidad de supervivencia.

En algunos casos, los pasajeros que viajaban con familiares pudieron haber tenido mayores probabilidades de recibir ayuda o apoyo durante la evacuación. Sin embargo, en otros casos los grupos familiares numerosos pudieron haber tenido mayores dificultades para evacuar rápidamente.

Este tipo de análisis permite explorar cómo las relaciones familiares dentro del barco pudieron influir en las probabilidades de supervivencia

7.1.6. Interpretación General de Dashboard

En conjunto, las visualizaciones incluidas en el dashboard permiten analizar diferentes dimensiones del problema de estudio.

El uso de gráficos interactivos facilita la exploración de los datos y permite identificar patrones que pueden no ser evidentes mediante el análisis numérico únicamente.

Además, el uso de filtros dinámicos permite al usuario seleccionar diferentes rangos de edad o clases de pasajeros, lo cual proporciona una experiencia interactiva que mejora la comprensión de los resultados.

Este enfoque demuestra la importancia de combinar técnicas de análisis estadístico con herramientas de visualización de datos para comunicar los resultados de manera clara y efectiva.

8. Discusión de Resultados

Los resultados obtenidos a partir del análisis estadístico permiten identificar patrones interesantes dentro del dataset del Titanic.

El contraste de hipótesis sugiere que existe una diferencia entre las edades promedio de los pasajeros que sobrevivieron y aquellos que no sobrevivieron. Esto indica que la edad pudo haber sido un factor relevante en las probabilidades de supervivencia.

Por otra parte, los modelos de regresión permitieron analizar relaciones entre diferentes variables presentes en el conjunto de datos. La regresión lineal permitió explorar la relación entre características demográficas y la tarifa pagada por los pasajeros.

La regresión logística permitió estimar probabilidades de supervivencia, lo cual constituye un enfoque útil para problemas de clasificación dentro de la ciencia de datos.

9. Conclusiones

El desarrollo de este proyecto permitió aplicar diferentes técnicas estadísticas y computacionales para analizar un conjunto de datos real.

A través del contraste de hipótesis fue posible evaluar afirmaciones acerca de diferencias entre grupos de pasajeros, proporcionando evidencia estadística sobre la influencia de ciertas variables en la supervivencia.

Los modelos de regresión implementados permitieron comprender mejor las relaciones entre las variables presentes en el dataset.

Finalmente, la implementación de un dashboard interactivo permitió transformar los resultados del análisis en una herramienta visual que facilita la interpretación de los datos.

Este tipo de herramientas es fundamental dentro del campo de la ciencia de datos, ya que permite comunicar resultados de manera clara, accesible e intuitiva.

10. Referencias Bibliográficas

Oehlert, G. (2010). A First Course in Design and Analysis of Experiments.

Plotly Technologies Inc. Dash Documentation.

The Turing Way (2021). Zero to Binder.

Kohavi, R., Longbotham, R., Sommerfield, D., & Henne, R. (2008). Controlled Experiments on the Web.